

Introducción a Machine Learning

Aprendizaje de Máquina – *Support Vector Machines*

MSc. Marco Sobrevilla

Objetivo



- Aprender conceptos sobre *Support Vector Machines*

Agenda




- *Introducción*
- *Support Vector Machines*
- *Kernel*

Support Vector Machines

- Propuesto por **Vladimir Vapnik**
- También conocido como: ***Large margin classifier***
- Busca una función de decisión óptima (***optimal hyperplane***)
- En la clasificación lineal no tiene problemas con óptimos locales (identifica el global).
- Aprovecha las funciones **kernel** para problemas de clasificación no lineales.

Support Vector Machines



- La idea es que margen grande posee bajo error de generalización
- Margen cortos son propensos a *overfitting*

Support Vector Machines

$$w_0 + \mathbf{w}^T \mathbf{x}_{pos} = 1$$

$$w_0 + \mathbf{w}^T \mathbf{x}_{neg} = -1$$

- Se busca minimizar:

$$\frac{1}{2} \|\mathbf{w}\|^2$$

$$\Rightarrow \mathbf{w}^T (\mathbf{x}_{pos} - \mathbf{x}_{neg}) = 2$$

$$\|\mathbf{w}\| = \sqrt{\sum_{j=1}^m w_j^2}$$

Maximizar
el margen

$$\frac{\mathbf{w}^T (\mathbf{x}_{pos} - \mathbf{x}_{neg})}{\|\mathbf{w}\|} = \frac{2}{\|\mathbf{w}\|}$$

Clases Linealmente no Separables

- SVM funciona bien para clases linealmente separables
- Qué pasa en otros casos?
 - *Soft-margin*
 - *C: Penalidad de clasificación errada*


$$\mathbf{w}^T \mathbf{x}^{(i)} \geq 1 \text{ if } y^{(i)} = 1 - \xi^{(i)}$$

$$\mathbf{w}^T \mathbf{x}^{(i)} < -1 \text{ if } y^{(i)} = 1 + \xi^{(i)}$$

Minimizar:

$$\frac{1}{2} \|\mathbf{w}\|^2 + C \left(\sum_i \xi^{(i)} \right)$$


Clases Linealmente no Separables




Disminuye bias
Aumenta la varianza

Aumenta bias
Disminuye varianza

Parámetro C




Problemas No Lineales



Necesitamos
transformarlo a un
espacio más
conveniente



Uso de Kernels



Funciones Conocidas

- linear: $K(\mathbf{x}_i, \mathbf{x}_j) = \mathbf{x}_i^T \mathbf{x}_j$.
- polynomial: $K(\mathbf{x}_i, \mathbf{x}_j) = (\gamma \mathbf{x}_i^T \mathbf{x}_j + r)^d$, $\gamma > 0$.
- radial basis function (RBF): $K(\mathbf{x}_i, \mathbf{x}_j) = \exp(-\gamma \|\mathbf{x}_i - \mathbf{x}_j\|^2)$, $\gamma > 0$.
- sigmoid: $K(\mathbf{x}_i, \mathbf{x}_j) = \tanh(\gamma \mathbf{x}_i^T \mathbf{x}_j + r)$.

Kernel SVM



Fin 😊